

A Predictive Auto-Scaling Framework for Microservices in Distributed Systems: A Cost-Performance Optimization Approach for U.S. Enterprises

https://www.artificialinteljournal.com/uploads/archives/20251128104735_AIE-2025-1-015.1.pdf

- 2025

1. Qual é o problema de pesquisa que o artigo busca resolver?

Como escalar microserviços de forma eficiente em ambientes de alta variabilidade de carga. Em arquiteturas tradicionais, o auto-scaling funciona de forma reativa, ou seja, o sistema só cresce depois que a demanda já aumentou. Isso gera dois cenários ruins: ou o sistema sofre com lentidão e falhas até reagir, ou escala demais e desperdiça recursos (e dinheiro).

A proposta do artigo é atacar exatamente esse ponto e tornar o processo de escalabilidade mais inteligente, antecipando a demanda e equilibrando melhor custo e desempenho.

2. Qual é o contexto ou domínio de aplicação do trabalho?

O trabalho está inserido no universo de cloud computing e arquiteturas de microserviços, que são a base de praticamente todos os sistemas modernos de grande escala, como plataformas de streaming, e-commerces e SaaS.

Ele foca especialmente em cenários corporativos, onde há grande volume de requisições e necessidade constante de otimização de custo. Apesar disso, as ideias são totalmente transferíveis para outros domínios, inclusive o teu foco com APIs de alto tráfego.

3. Qual é a principal pergunta de pesquisa ou hipótese levantada pelos autores?

Se é possível prever o comportamento da carga do sistema e usar essa previsão para tomar decisões melhores de escalabilidade do que os métodos tradicionais.

A hipótese dos autores é que sim, e além disso, que uma abordagem preditiva consegue melhorar simultaneamente dois pontos que normalmente entram em conflito: desempenho e custo.

4. Quais são os métodos ou abordagens utilizadas (algoritmos, modelos, técnicas)?

Propõe um framework de auto-scaling preditivo, que combina análise de dados históricos com modelos de machine learning para prever picos de demanda.

Em vez de depender de thresholds fixos, o sistema analisa padrões ao longo do tempo e tenta antecipar quando a carga vai subir.

Com isso, ele ajusta automaticamente o número de instâncias dos micro serviços antes que o problema aconteça.

A abordagem mistura conceitos de:

- previsão de séries temporais
- análise de comportamento de carga
- automação de infraestrutura

5. Quais dados ou bases de dados foram utilizados no estudo?

São utilizados dados reais de ambientes corporativos, com histórico de uso dos sistemas:

- volume de requisições ao longo do tempo
- consumo de CPU e memória
- variações de carga em horários diferentes

Isso é importante porque dá mais credibilidade ao modelo.

6. Como foi feito o desenho do experimento ou da avaliação?

O experimento basicamente compara duas abordagens:

- auto-scaling tradicional (reativo)
- auto-scaling preditivo (proposto no artigo)

Eles simulam diferentes cenários de carga, incluindo picos e variações bruscas e observam como cada abordagem se comporta.

7. Quais métricas de avaliação foram utilizadas para medir os resultados?

As métricas são bem completas e cobrem tanto o lado técnico quanto o financeiro:

- latência (tempo de resposta)
- throughput (quantidade de requisições processadas)
- uso de CPU/memória
- custo operacional (infraestrutura)

Isso é interessante porque conecta diretamente com o mundo real.

8. Quais foram os principais resultados ou conclusões do artigo?

Os resultados mostram que o modelo preditivo consegue:

- reduzir o tempo de resposta em momentos de pico
- evitar sobrecarga do sistema
- diminuir custos ao evitar escalonamento desnecessário

Ou seja, ele consegue equilibrar melhor desempenho e custo. A principal conclusão é que antecipar a demanda é mais eficiente do que simplesmente reagir a ela.

9. Quais são as limitações apontadas pelos autores?

Algumas limitações são:

- depende de dados históricos consistentes para funcionar bem
- pode ter dificuldade em cenários totalmente imprevisíveis
- exige uma infraestrutura mais complexa para implementação

10. Que oportunidades de pesquisa futura ou lacunas o artigo indica?

O artigo abre espaço para várias evoluções:

- modelos que aprendem em tempo real;
- integração com outras camadas do sistema;

- adaptação para cenários mais dinâmicos e imprevisíveis.

Também dá margem pra explorar como esse tipo de abordagem pode ser simplificada ou tornar-se mais acessível.

11. O que deste artigo pode contribuir ou inspirar o seu trabalho?

Esse artigo encaixa muito bem com o teu tema porque traz uma mudança de mentalidade.

Em vez de só reagir a problemas de desempenho em APIs, você pode pensar em sistemas que antecipam esses problemas.

- pensar em otimização de APIs com base em previsão de carga
- explorar automação inteligente em vez de regras fixas
- conectar performance com custo (o que é muito forte em TCC)