

The Role of AI in Optimizing Cloud-Native API Architectures

<https://ijarsct.co.in/Paper24402.pdf>

- 2025

1. Qual é o problema de pesquisa que o artigo busca resolver?

O artigo tenta lidar com um problema mais amplo e, ao mesmo tempo, mais profundo, que é a complexidade de sistemas cloud-native.

Múltiplos serviços, APIs interagindo o tempo inteiro, cargas variando, falhas surgindo em pontos inesperados exigem decisões constantes e o problema é que essas decisões ainda são, em grande parte:

- manuais
- baseadas em regras fixas
- reativas

2. Qual é o contexto ou domínio de aplicação do trabalho?

Totalmente inserido em:

- cloud-native architectures
- microservices
- APIs em larga escala

Ou seja, ambientes modernos, distribuídos, que precisam lidar com:

- alta disponibilidade
- milhões de requisições
- mudanças constantes de carga

Isso inclui facilmente:

- streaming
- fintechs
- plataformas de e-commerce
- sistemas corporativos grandes

Basicamente o cenário real de produção hoje.

3. Qual é a principal pergunta de pesquisa ou hipótese levantada pelos autores?

Até que ponto técnicas de IA conseguem melhorar a performance, escalabilidade e confiabilidade de APIs em ambientes cloud-native?

A hipótese é que sim, e que sistemas com IA conseguem tomar decisões melhores do que abordagens tradicionais baseadas em regras estáticas.

4. Quais são os métodos ou abordagens utilizadas (algoritmos, modelos, técnicas)?

Ele não propõe um único modelo, mas analisa várias formas de usar IA:

- Machine Learning para prever carga e comportamento
- Reinforcement Learning para tomada de decisão adaptativa
- Análise preditiva para detectar falhas antes que aconteçam
- Otimização automática de recursos (CPU, memória, instâncias)

Também discute uso de IA em:

- balanceamento de carga
- auto-scaling
- detecção de anomalias

Ou seja, a IA aparece como um “cérebro” distribuído pelo sistema.

5. Quais dados ou bases de dados foram utilizados no estudo?

Como é um artigo mais analítico e conceitual, ele não depende de um único dataset específico.

Ele se baseia em:

- dados operacionais de sistemas (logs, métricas, tráfego)
- estudos de caso
- simulações

Esses dados representam o comportamento real das APIs:

- picos de uso
- falhas
- padrões de requisição

6. Como foi feito o desenho do experimento ou da avaliação?

O artigo trabalha mais com:

- análise de diferentes abordagens existentes
- comparação de cenários com e sem IA
- estudos de caso

Ele mostra como sistemas se comportam quando usam:

- decisões estáticas
 - vs
- decisões baseadas em aprendizado

É mais uma visão estratégica do que um teste isolado.

7. Quais métricas de avaliação foram utilizadas para medir os resultados?

- latência
- throughput
- taxa de erro
- uso de recursos
- disponibilidade

Vale ressaltar:

- eficiência da tomada de decisão (o quão bem o sistema se adapta)

8. Quais foram os principais resultados ou conclusões do artigo?

A principal conclusão é que a IA tem um potencial enorme para transformar a forma como APIs são gerenciadas, permitindo:

- antecipar problemas
- reagir mais rápido a mudanças
- otimizar recursos automaticamente
- melhorar a estabilidade geral

Mas também deixa claro que isso ainda está em evolução e não é algo completamente resolvido.

9. Quais são as limitações apontadas pelos autores?

- necessidade de muitos dados para treinar modelos
- complexidade de implementação
- custo computacional
- dificuldade de interpretação das decisões da IA (caixa preta)

10. Que oportunidades de pesquisa futura ou lacunas o artigo indica?

- tornar modelos de IA mais leves e eficientes
- melhorar a explicabilidade das decisões
- integrar IA com arquiteturas reais de produção
- criar sistemas mais autônomos (self-healing systems)

Também abre caminho para combinar várias técnicas e não só uma abordagem isolada.

11. O que deste artigo pode contribuir ou inspirar o seu trabalho?

Ele mostra que:

- otimização não precisa ser só reativa
- sistemas podem aprender com o próprio comportamento
- APIs podem ser gerenciadas de forma inteligente e automática

Conecta tudo que foi visto em outros artigos:

- auto-scaling
- performance
- arquitetura
- tomada de decisão